

Resolução de sistemas lineares

(6)

1. Métodos diretos

1.1 - Resolução de sistemas triangulares

Um sistema triangular (superior) tem a forma:

$$\underbrace{\begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ & a_{22} & a_{23} & \dots & a_{2n} \\ & & \ddots & & \\ & & & a_{nn} \end{bmatrix}}_{A^{n \times n}} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}}_{X} = \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}}_{b^{n \times 1}} \quad (1)$$

$\nearrow \tilde{n}$ pode ser singular!!!

A resolução de um sistema deste tipo é bastante simples, e intuitivo. Começando pela última equação temos: $a_{nn} x_n = b_n \Rightarrow x_n = \frac{b_n}{a_{nn}}$

Agora, na penúltima equação temos: $a_{n-1,n-1} x_{n-1} + a_{n-1,n} x_n = b_{n-1}$

$$\Rightarrow x_{n-1} = \frac{b_{n-1} - a_{n-1,n} x_n}{a_{n-1,n-1}} \sim \text{conhecido!}$$

Note então que podemos escrever um algoritmo para calcular o vector de incógnitas recursivamente:

$$x_n = \frac{b_n}{a_{nn}}$$

Para $k = (n-1), \dots, 1$

$$s = 0$$

Para $j = (k+1), \dots, n$

$$s = s + a_{kj} x_j$$

$$x_k = \frac{(b_k - s)}{a_{kk}}$$

Fim

Fim

(2)

Então, para resolvermos computacionalmente sistemas lineares, (7) basta transformá-los em sistemas triangulares equivalentes (que tenham a mesma solução) e aplicar o ~~algoritmo~~ algoritmo (2). equivalente (1)

1.2 - Eliminação de Gauss

Para transformar qualquer sistema em triangular superior, podemos realizar 3 operações:

- trocar duas equações;
- multiplicar uma equação por uma constante não nula;
- adicionar um múltiplo de uma equação a uma outra equação.

O método deixa zero em cada coluna todos os elementos abaixo da diagonal principal.

$$\text{Ex: } \underbrace{\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix}}_{A^{(0)}} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}}_{b^{(0)}} = \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}}_{b^{(0)}} \quad (3)$$

Para zerar o a_{21} fazemos a segunda equação - $\frac{a_{21}}{a_{11}} \times$ a primeira equação. Para zerar o a_{31} fazemos a 3ª equação - $\frac{a_{31}}{a_{11}} \times$ 1ª equação e assim por diante. O elemento a_{11} é chamado pivô da 1ª coluna! O resultado desta 1ª rodada de eliminação

Gaussiana seria:

$$\underbrace{\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ 0 & a_{22} & a_{23} & a_{24} \\ 0 & a_{32} & a_{33} & a_{34} \\ 0 & a_{42} & a_{43} & a_{44} \end{bmatrix}}_{A^{(1)}} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}}_{b^{(1)}} = \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}}_{b^{(1)}} \quad (4)$$

Para gerar os elementos da 2ª coluna abaixo de a'_{22} procede-se

de uma maneira análoga. Por exemplo, para gerar a'_{32}

fazemos 3ª equação - $\frac{a'_{32}}{a'_{22}} \times 2^\text{a}$ equação. Para gerar a'_{42}

fazemos 4ª equação - $\frac{a'_{42}}{a'_{22}} \times 2^\text{a}$ equação. O novo sistema

equivalente seria:

$$\underbrace{\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ 0 & a'_{22} & a'_{23} & a'_{24} \\ 0 & 0 & a''_{33} & a''_{34} \\ 0 & 0 & a''_{43} & a''_{44} \end{bmatrix}}_{A^{(2)}} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}}_{x} = \underbrace{\begin{bmatrix} b_1 \\ b'_2 \\ b''_3 \\ b''_4 \end{bmatrix}}_{b^{(2)}} \quad (5)$$

procedendo de modo análogo podemos gerar a''_{43} . Desta maneira obtemos um sistema triangular superior equivalente.

Para concluir: Resolva o sistema acima utilizando eliminador de Gauss

$$\begin{cases} 3x_1 + 2x_2 + 4x_3 = 1 \\ x_1 + x_2 + 2x_3 = 2 \\ 4x_1 + 3x_2 - 2x_3 = 3 \end{cases}$$

1.3 - Estratégias de pivoteamento

Considere o sistema:

$$\begin{cases} 0.0002x_1 + 2x_2 = 5 \\ 0.2x_1 + 2x_2 = 6 \end{cases}$$

Vamos trabalhar com aritmética de 3 dígitos:

$$\Rightarrow 0.2 \times 10^{-3}x_1 + 0.2 \times 10^1x_2 = 0.5 \times 10^1$$

$$0.2 \times 10^1x_1 + 0.2 \times 10^1x_2 = 0.6 \times 10^2$$

Etapa 1: Pivo = 0.2×10^{-3}

$$L2 - \frac{a_{21}}{a_{11}} \times L1 \rightarrow L2 \text{ ou seja } 0.2 \times 10^1 - \frac{0.2 \times 10^1}{0.2 \times 10^{-3}} \times 0.2 \times 10^{-3} = a'_{21} = 0$$

$$\begin{aligned} a_{22} &= 0.2 \times 10^1 - \frac{0.2 \times 10^1}{0.2 \times 10^{-3}} \cdot 0.2 \times 10^1 = 0.2 \times 10^1 - 0.1 \times 10^5 \times 0.2 \times 10^1 \\ &= 0.2 \times 10^1 - 0.2 \times 10^5 \\ &= 0.00002 \times 10^5 - 0.2 \times 10^5 \\ &= -0.19998 \times 10^5 \Rightarrow -0.2 \times 10^5 \quad (\text{arredondando!}) \end{aligned} \quad (9)$$

$$b_2 = 0.6 \times 10^1 - \frac{0.2 \times 10^1}{0.2 \times 10^{-3}} \cdot 0.5 \times 10^1 = 0.6 \times 10^1 - \frac{0.1 \times 10^5 \cdot 0.5 \times 10^1}{0.5 \times 10^5} = -0.49994 \times 10^5$$

$\downarrow$
 -0.5×10^5

Logo o novo sistema equivalente x' :

$$\begin{bmatrix} 0.2 \times 10^{-3} & 0.2 \times 10^1 \\ 0 & -0.2 \times 10^5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0.5 \times 10^1 \\ -0.5 \times 10^5 \end{bmatrix}$$

$$\text{Logo } x_2 = \frac{-0.5 \times 10^5}{-0.2 \times 10^5} = 0.25 \times 10^1 \quad \text{e} \quad \frac{0.5 \times 10^1 - 0.2 \times 10^1 \times 0.25 \times 10^1}{0.2 \times 10^{-3}} = x_1$$

$$\Rightarrow x_1 = \frac{0.5 \times 10^1 - 0.5 \times 10^1}{0.2 \times 10^{-3}} = 0$$

Utilizando os valores obtidos, verificamos que eles não satisfazem as equações!!! Isso ocorre quando o pivô é muito pequeno! Para evitar, utilizamos

estratégias de pivoteamento para "trazer" elementos com módulo grande para a posição do pivô. A estratégia mais utilizada é o pivoteamento parcial. Consiste em, em cada etapa, trazer o elemento de maior módulo (que pode estar localizado na diagonal principal ou abaixo dela)

Para a diagonal principal, permutando as linhas correspondentes.

Por exemplo:

1ª etapa:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix}$$

2ª etapa:

$$\begin{bmatrix} a'_{11} & a'_{12} & a'_{13} & a'_{14} \\ 0 & a'_{22} & a'_{23} & a'_{24} \\ 0 & a'_{32} & a'_{33} & a'_{34} \\ 0 & a'_{42} & a'_{43} & a'_{44} \end{bmatrix}$$

e assim por diante //

Procurar na 1ª coluna o elemento de maior módulo e levá-lo p/a diagonal principal. procurar agora

Para com: Resolva novamente o sistema anterior, desta vez (10)
utilizando a técnica do pivoteamento parcial.

2 - Métodos iterativos

Imensos sistemas lineares, que surgem de problemas práticos como discretização de equações diferenciais por elementos finitos ou diferenças finitas e descrição de redes de potência, são de grande porte com matriz dos coeficientes esparsa. Para estes casos, são adotados esquemas especiais para armazenamento da matriz A , que tenham proveito de sua esparsidade. Os métodos diretos quando aplicados a estes casos, provocam preenchimentos na matriz A , o que não é desejável. Nesses casos, métodos iterativos podem ser preferíveis.

Além disso, visto que métodos diretos apresentam sérios problemas com erros de arredondamento. Os métodos iterativos por sua vez, conforme será visto a seguir, tem menores erros de arredondamento, visto que com convergência, uma vez assegurada, independe da aproximação inicial.

A ideia central dos métodos iterativos é generalizar o método do ponto fixo utilizado na busca de raízes de uma equação que será visto mais adiante. Equação de ponto fixo: $x = \psi(x)$

2.1 - Método de Gauss-Jacobi ^{aplicação} _{função qualquer}

No método de Gauss-Jacobi transformamos o sistema $Ax = b$ em um problema equivalente de ponto fixo $x = Cx + g$. Para tanto, isolamos x_k na k -ésima equação, conforme visto a seguir. Considere o sistema $n \times n$:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases} \quad (1)$$

Supondo $a_{ii} \neq 0$, $i = 1, 2, \dots, n$ (se não, podemos efetuar permutações de linhas) (1)
 Para garantir isso, fazemos:

$$\begin{cases} x_1 = \frac{1}{a_{11}} (b_1 - a_{12}x_2 - a_{13}x_3 - \dots - a_{1n}x_n) \\ x_2 = \frac{1}{a_{22}} (b_2 - a_{21}x_1 - a_{23}x_3 - \dots - a_{2n}x_n) \\ \vdots \\ x_n = \frac{1}{a_{nn}} (b_n - a_{n1}x_1 - a_{n2}x_2 - \dots - a_{n,n-1}x_{n-1}) \end{cases} \quad (2)$$

Deixa forma, matricialmente temos $x = Cx + g$, onde:

$$C = \begin{bmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} & \dots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} & \dots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & -\frac{a_{n3}}{a_{nn}} & \dots & 0 \end{bmatrix} \quad (3)$$

$$g = \begin{bmatrix} b_1/a_{11} \\ b_2/a_{22} \\ b_3/a_{33} \\ \vdots \\ b_n/a_{nn} \end{bmatrix} \quad (4)$$

aprox. inicial

O método de Gauss-Jacobi consiste em, dado $x^{(0)}$, obter $x^{(1)}, x^{(2)}, \dots, x^{(k)}, \dots$ através da relação recursiva $x^{(k+1)} = Cx^{(k)} + g$. Note
que podemos utilizar a forma (2) para o esquema iterativo.

Critério de parada:

(12)

O processo iterativo é repetido até que o vetor $x^{(k)}$ esteja suficientemente próximo do vetor $x^{(k-1)}$. Uma das maneiras de se medir a distância entre $x^{(k)}$ e $x^{(k-1)}$ é calcular:

$$d^{(k)} = \max_{1 \leq i \leq n} |x_i^{(k)} - x_i^{(k-1)}| \quad (5)$$

Assim, dada uma precisão ε , o vetor $x^{(k)}$ será aceito como $\bar{x}$, aproximação da solução exata, se $d^{(k)} < \varepsilon$.

Entretanto, o critério de parada mais utilizado utiliza o conceito de erro relativo, onde calculamos

$$d_r^{(k)} = \frac{d^{(k)}}{\max_{1 \leq i \leq n} |x_i^{(k)}|} \quad (6)$$

Exemplo: (Exemplo 10 do livro - pág 157)

Um critério de convergência ~~é~~ Critério dos linhos)

Seja o sistema linear $Ax=b$ e seja $\alpha_k = \left(\frac{\sum_{j=1, j \neq k}^n |a_{kj}|}{|a_{kk}|} \right)$. Se $\alpha = \max_{1 \leq k \leq n} \alpha_k < 1$,

então o método de Gauss-Jacobi converge para a solução do sistema dado independente da aproximação inicial. Note que a condição acima é suficiente para a convergência mas não necessária!

2.2 - Método de Gauss-Seidel

A diferença entre o método de Gauss-Seidel para o método de Gauss-Jacobi é que em Gauss-Seidel já utilizamos as aproximações previamente atualizadas $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{j-1}^{(k+1)}$ na atualização de $x_j^{(k+1)}$, ou seja:

(13)

$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12} x_2^{(k)} - a_{13} x_3^{(k)} - \dots - a_{1n} x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21} x_1^{(k+1)} - a_{23} x_3^{(k)} - \dots - a_{2n} x_n^{(k)}) \\ x_3^{(k+1)} = \frac{1}{a_{33}} (b_3 - a_{31} x_1^{(k+1)} - a_{32} x_2^{(k+1)} - a_{34} x_4^{(k)} - \dots - a_{3n} x_n^{(k)}) \\ \vdots \\ x_m^{(k+1)} = \frac{1}{a_{mm}} (b_m - a_{m1} x_1^{(k+1)} - a_{m2} x_2^{(k+1)} - a_{m3} x_3^{(k+1)} - \dots - a_{m, m-1} x_{m-1}^{(k+1)}) \end{cases} \quad (7)$$

Exemplo: Exemplo 14 do livro

Critério de convergência (Critério de Sassenfeld):

$$\text{Sejam } \beta_j = \frac{|a_{12}| + |a_{13}| + \dots + |a_{1m}|}{|a_{11}|}$$

$$\beta_j = \frac{|a_{j2}| \beta_1 + |a_{j3}| \beta_2 + \dots + |a_{j, j-1}| \beta_{j-1} + |a_{j, j+1}| + \dots + |a_{jm}|}{|a_{jj}|} \quad (8)$$

Seja $\beta = \max_{1 \leq j \leq n} \{\beta_j\}$. Se $\beta < 1$, então o método de Gauss-Seidel gera

uma sequência convergente para a solução do sistema qualquer que seja o "chute" inicial $x^{(0)}$. Além disso, quanto menor for β mais rápida será a convergência.

Exemplo: Exemplo 15 do livro (pág 174)


Obs: Note que se o critério dos linhos for satisfeito, automaticamente o critério de Sassenfeld será satisfeito. Mas, por outro lado, o critério de Sassenfeld pode ser satisfeito mesmo que o critério dos linhos não o seja.

1 - Introdução

A ideia central dos métodos apresentados aqui é partir de uma aproximação inicial para a raiz e em seguida refinar essa aproximação através de um processo iterativo. Nesse sentido, o processo para a determinação de raízes pode ser dividido a grosso modo em duas fases:

- Identificação de um intervalo que contenha a raiz
- Refinamento, que consiste em, a partir da aproximação inicial escolhida (conforme o item a), melhorá-la sucessivamente até se obter uma aproximação para a raiz dentro da precisão ϵ pré-fixada.

2 - Fase 1 - Identificação de um intervalo que contenha a raiz



Se $f(x)$ é contínua e $f(a) \cdot f(b)$ tem sinais diferentes, então existe pelo menos uma raiz em $[a, b]$. Além disso, se $f'(x)$ existir e preservar sinal em $[a, b]$, então essa raiz é única em $[a, b]$.

Nessa fase realizamos uma análise técnica (e muitas vezes gráfica) da função.

3 - Fase 2 - Refinamento

A forma como se efetua o refinamento é ^oque diferencia os métodos. Todos eles, pertencem a classe dos métodos iterativos.

3.1 Critérios de parada

(15)

Que testes efetuar para saber se x_k está suficientemente próximo da raiz exata?

O teste mais utilizado é:

$$|f(x_k)| < \varepsilon \quad (1)$$

onde ε é uma precisão desejada. Dois outros t_3, t_4 também são comumente utilizados:


a) $|x_k - \xi| < \varepsilon \quad (2)$ onde ξ é o valor exato da raiz.

b) $\frac{|f(x_k)|}{L} < \varepsilon \quad (3)$ onde $L = |f'(x)|$ para algum x escolhido

nas vizinhanças de ξ .

3.2 - Método da Bisseção

Vamos supor, para simplificar, que o intervalo $[a, b]$ contenha uma única raiz da equação $f(x) = 0$. O objetivo deste método é reduzir a amplitude do intervalo que contém a raiz até se atingir a precisão requerida, $(b_k - a_k) < \varepsilon$, utilizando para isso sucessivas divisões de $[a_k, b_k]$ ao meio. Graficamente temos:



Intuitivamente, podemos perceber que o método sempre converge 16
para a raiz desejada, independentemente do tamanho de $[a, b]$,
desde que exista uma raiz em $[a, b]$.

É possível estimar o nº de iterações necessárias para se obter uma
aproximação para a raiz dada uma precisão ϵ (ou seja, $b_k - a_k < \epsilon$).

Vimos que $b_k - a_k = \frac{b_{k-1} - a_{k-1}}{2} = \frac{b_0 - a_0}{2^k}$. Se quisermos $b_k - a_k < \epsilon$

$$\Rightarrow \frac{b_0 - a_0}{2^k} < \epsilon \Rightarrow 2^k > \frac{b_0 - a_0}{\epsilon} \Rightarrow k \log(2) > \log(b_0 - a_0) - \log(\epsilon)$$

$$\Rightarrow k > \frac{\log(b_0 - a_0) - \log(\epsilon)}{\log(2)} \quad // \quad (5)$$

Exemplo: (Exemplo 4 da pág 44)

3.3 - Método da falsa posição

Vimos que podemos conseguir uma raiz aproximada $\bar{x}$ de uma equação
utilizando os informações sobre os valores disponíveis de $f(x)$ a cada iteração.

No método da Bisseção reduziamos o intervalo que contém a raiz
à metade simplesmente fazendo a média aritmética entre a_k e b_k ,

$$a_{k+1} \text{ (ou } b_{k+1}, \text{ dependendo do sinal)} = \frac{a_k + b_k}{2}.$$


Mos note que $f(a_k)$ pode estar muito mais perto de zero que $f(b_k)$ (ou
vice versa). O método da falsa posição supõe então que nesse caso
a raiz estaria mais perto de a_k que de b_k (pelo menos isso ocorre quando
 $f(x)$ é linear em $[a_k, b_k]$). ^{analogamente,} No caso de $f(b_k)$ estar muito mais
perto de zero que $f(a_k)$, o método supõe que a raiz esteja mais perto
de b_k que de a_k .

No sentido do que está dito acima, em vez de tomar a média ⁽¹⁷⁾ aritmética entre a_k e b_k , o método da falsa posição toma a média aritmética ponderada entre a_k e b_k com pesos $|f(b_k)|$ e $|f(a_k)|$, respectivamente:

$$a_{k+1} \text{ (ou } b_{k+1}) = x_k = \frac{a_k |f(b_k)| + b_k |f(a_k)|}{|f(b_k)| + |f(a_k)|} = \frac{a_k f(b_k) - b_k f(a_k)}{f(b_k) - f(a_k)} \quad (6)$$

visto que $f(a_k)$ e $f(b_k)$ têm sinais opostos.

Graficamente, a nova extremidade do intervalo é a intersecção entre o eixo "x" e a recta $t(x)$ que passa por $(a_k, f(a_k))$ e $(b_k, f(b_k))$:



Exemplo: (Exemplo 5 do livro - pag 49)

Convergência: Da mesma forma que o método da bissecção, este método sempre converge para a raíz desejada, desde que $f(x)$ seja contínua em $[a_0, b_0]$.

Obs: Diferentemente do método da Bisseção, o critério de parada mais ⁽¹⁸⁾ utilizado aqui é $f(x_k) < \epsilon$.

3.4 - Iteração de ponto fixo

A iteração de ponto fixo é baseada na equação ^{chamada} de ponto fixo, que tem a forma:

$$x = \psi(x) \quad (7), \text{ onde } \psi \text{ é uma função qualquer de } x$$

A iteração de ponto fixo gera uma sequência $\{x_k\}$ através da relação:

$$x_{k+1} = \psi(x_k) \quad (8),$$

a partir de um valor inicial x_0 -
(na verdade infinito!)

Existem várias formas diferentes de transformar o nosso problema original $f(x) = 0$ em um problema de ponto fixo equivalente $x = \psi(x)$. Por exemplo, a equação $x^2 + x - 6 = 0$ pode ser reescrita de várias formas, dentre as quais:

$$a) x = (6 - x^2) \sim \psi_1(x)$$

$$b) x = \pm \sqrt{6 - x} \sim \psi_2(x)$$

$$c) x = \frac{6}{x} - 1 \sim \psi_3(x) \quad (9)$$

$$d) x = \frac{6}{x+1} \sim \psi_4(x)$$



As funções ψ_i em (9) são conhecidas como "funções de iteração" para o problema original $f(x) = 0$. Note ^{que} as raízes que satisfazem a equação original $x^2 + x - 6 = 0$ também vão satisfazer cada uma das equações em (9).

A forma geral das funções de iteração $\psi(x)$ é:

$$\psi(x) = x + A(x)f(x) \quad (10),$$

Com a condição que em ξ , ponto fixo de $\psi(x)$, se tenha $A(\xi) \neq 0$

Graficamente, uma raiz da equação $x = \psi(x)$ é a abscissa do ponto de interseção da reta $y = x$ com a curva $y = \psi(x)$:



Nos figuras (10a) e (10b) estão representados as iterações com os sucessivos valores para a aproximação x_k . Note que enquanto em (10a) a iteração de ponto fixo converge, em (10b) a iteração de ponto fixo diverge!!!

Logo, não é para qualquer escolha de $\psi(x)$ que o processo recursivo definido por $x_{k+1} = \psi(x_k)$ gera uma sequência que converge para ξ .

convergência:

Seja ξ uma raiz da equação $f(x)=0$, isolada num intervalo I centrada em ξ e seja $\psi(x)$ uma função de iteração para a equação $f(x)=0$. Se

- i) $\psi(x)$ e $\psi'(x)$ são contínuas em I ,
- ii) $|\psi(x)| \leq M < 1, \forall x \in I$ e
- iii) $x_0 \in I$,

(11)

então a sequência $\{x_k\}$ gerada pelo processo iterativo $x_{k+1} = \psi(x_k)$ converge para ξ . //

Além disso, prova-se que se a sequência é convergente

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k} = \psi'(\xi) = \text{Constante} < 1 \quad (12) \quad \text{onde } e_k \text{ é o erro associado (por 11.i)}$$

a última aproximação, $x_k - \xi$. Isso nos diz que para k muito grande o erro associado a uma aproximação é diretamente proporcional a aproximação anterior, com constante de proporcionalidade $\psi'(\xi)$. Essa conclusão também se aplica para k menores e é a base de funcionamento do método de Newton que será visto a seguir.

3.5 - Método de Newton - Raphson

O que o método de Newton faz, na tentativa de garantir e acelerar a convergência da iteração de ponto fixo é escolher como função de iteração a função $\psi(x)$ tal que $\psi(\xi) = 0$. Isso nos dá que:


$$\psi(x) = x - \frac{f(x)}{f'(x)} \quad (12) \quad (\text{verifique!!!})$$

e o processo iterativo fica:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \quad (13) \quad //$$

Gráficamente temos:

(21)



Convergência:

Prova-se que uma vez escolhida uma aproximação inicial próxima o bastante da raiz ξ , a sequência gerada pelo processo iterativo convergirá para a mesma. Normalmente utiliza-se um método de convergência mais lenta, tal como o método da Bisseção, para determinar uma "boa" aproximação inicial para o método de Newton.

Obs: Note que o método tem dificuldades para convergir quando

$$|f'(\xi)| \approx 0.$$

Na forma

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = C \quad (14)$$

"p" é chamada ordem de convergência da sequência $\{x_k\}$ e "C" é a constante assintótica ao erro. Para o método de Newton mostrar-se que $p=2$, o que significa que a convergência é quadrática, taxa de convergência máxima que um método baseado na iteração de ponto fixo pode ter.

3.6 - Método da secante

(22)

Uma grande vantagem do método de Newton é a necessidade de se obter $f'(x)$ e calcular o seu valor numérico em cada iteração. Uma de ~~re~~ contornar esse problema é substituir a derivada $f'(x_k)$ pelo quociente das diferenças:


$$f'(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}} \quad (15)$$

Onde x_k e x_{k-1} são duas aproximações para a raiz. Então o processo iterativo pode ser escrito como:

$$x_{k+1} = \frac{x_{k-1} f(x_k) - x_k f(x_{k-1})}{f(x_k) - f(x_{k-1})} \quad (16)$$

As condições para a convergência do método da secante são praticamente as mesmas para a convergência do método de Newton. Note que o método encontra dificuldades de convergência quando $f(x_k) \approx f(x_{k-1})$ //

Gráficamente temos:



As condições para a convergência ^{aqui} são praticamente as mesmas para a convergência do método de Newton. Note ainda que o método pode divergir quando $f(x_k) \approx f(x_{k-1})$.

Neste método $P \approx 1.618$ (17).
 $\uparrow$ ordem de convergência

1 - Introdução

Um sistema de equações não lineares, tem a forma:

$$f_1(x_1, x_2, \dots, x_n) = 0$$

$$f_2(x_1, x_2, \dots, x_n) = 0 \quad (1)$$

$\vdots$

$$f_n(x_1, x_2, \dots, x_n) = 0$$

onde cada f_i é uma função dos n variáveis.

Utilizando a notação vetorial para representar este sistema de n equações não-lineares e n incógnitas, podemos escrever:

$$\underline{F}(\underline{x}) = \underline{0} \quad (2)$$

$$\text{onde } \underline{F}(x_1, x_2, \dots, x_n) = \left(f_1(x_1, x_2, \dots, x_n), f_2(x_1, x_2, \dots, x_n), \dots, f_n(x_1, x_2, \dots, x_n) \right)^T \quad (3)$$

a aplicação de

Para o problema aqui descrito, um método de solução análogo ao método da Bisseção não é tarefa trivial. Entretanto, no que foi visto anteriormente, um processo iterativo para resolver uma equação do tipo $f(x) = 0$ foi desenvolvido primeiramente transformando-se a equação em uma forma de ponto fixo $x = \Phi(x)$. Um processo iterativo similar será investigado aqui. No presente contexto, a forma de ponto fixo é definida como:

$$\underline{x} = \underline{\Phi}(\underline{x}) \quad (4)$$

2 - Método de Newton

24

No caso unidimensional temos que ^{em} um método de ponto fixo apropriado, a função de iteração escrita na forma:

$$f(x) = x + A(x)f(x) \quad (1)$$

resulta em convergência quadrática quando $A(x)$ é escolhido como:

$$A(x) = -\frac{1}{f'(x)} \quad (2)$$

Deste modo, definiremos a iteração correspondente ao método de Newton:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \quad (3)$$

No caso n -dimensional, a utilização de uma abordagem similar envolve uma matriz.

$$\underline{\underline{A}}(x) = \begin{bmatrix} a_{11}(x) & a_{12}(x) & \dots & a_{1n}(x) \\ a_{21}(x) & a_{22}(x) & \dots & a_{2n}(x) \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1}(x) & a_{n2}(x) & \dots & a_{nn}(x) \end{bmatrix} \quad (4)$$

em que cada um dos elementos $a_{ij}(x)$ é uma função de $\mathbb{R}^n$ em $\mathbb{R}$. Mais especificamente, esta abordagem requer que seja encontrado $\underline{\underline{A}}(x)$ tal que

$$\underline{\underline{\Phi}}(x) = x - \underline{\underline{A}}(x)^{-1} F(x) \quad (5)$$

resulte em um método com convergência quadrática para a

Solução de $\tilde{F}(\tilde{x}) = 0$, supondo que $A(\tilde{x})$ seja não-singular
Perto do ponto fixo $\tilde{x}$ de $\tilde{\Phi}$. Prova-se que essa matriz é a
matriz Jacobiana associada ao problema, dada por:

$$\tilde{J}(\tilde{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1}(\tilde{x}) & \frac{\partial f_1}{\partial x_2}(\tilde{x}) & \dots & \frac{\partial f_1}{\partial x_n}(\tilde{x}) \\ \frac{\partial f_2}{\partial x_1}(\tilde{x}) & \frac{\partial f_2}{\partial x_2}(\tilde{x}) & \dots & \frac{\partial f_2}{\partial x_n}(\tilde{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1}(\tilde{x}) & \frac{\partial f_n}{\partial x_2}(\tilde{x}) & \dots & \frac{\partial f_n}{\partial x_n}(\tilde{x}) \end{bmatrix} \quad (6)$$

Logo, a função de iteração fica

$$\tilde{\Phi}(\tilde{x}) = \tilde{x} - \tilde{J}^{-1}(\tilde{x}) \tilde{F}(\tilde{x}) \quad (7)$$

e a sequência iterativa fica:

$$\tilde{x}_{k+1} = \tilde{x}_k - \tilde{J}^{-1}(\tilde{x}_k) \tilde{F}(\tilde{x}_k) \quad (8)$$

A iteração (8) é chamada Método de Newton para sistemas não-lineares, do qual, geralmente espera-se a convergência quadrática.

Uma vulnerabilidade do método de Newton é a necessidade de se calcular e inverter a matriz $\tilde{J}(\tilde{x})$ em cada passo. Na prática, o cálculo explícito de $\tilde{J}^{-1}(\tilde{x})$ é evitado fazendo-se a operação em um modo de dois passos. Primeiro, encontra-se um vetor $\tilde{z}$ que satisfaça $\tilde{J}(\tilde{x}_k) \tilde{z} = -\tilde{F}(\tilde{x}_k)$ (9)

Obviamente, podemos resolver $\tilde{g}^{(k)}$ por (8), calculamos $\tilde{x}_{k+1}$ fazendo:

$$\tilde{x}_{k+1} = \tilde{x}_k + \tilde{y} \quad (10)$$

Note que determinamos o vetor $\tilde{y}$ resolvendo o sistema linear representado em (9)!

3- Método da secante

No método da secante para sistemas não-lineares aproximamos a matriz Jacobiana utilizando a forma de diferenças finitas:

$$J_{ij}^{(k)} = \frac{f_i(x_1^{(k)}, x_2^{(k)}, \dots, x_j + \epsilon, x_{j+1}^{(k)}, \dots, x_N^{(k)}) - f_i(x_1^{(k)}, x_2^{(k)}, \dots, x_j, x_{j+1}^{(k)}, \dots, x_N^{(k)})}{\epsilon}$$

ou seja, calculamos a j -ésima coluna de $\tilde{J}$ perturbando a j -ésima entrada $\tilde{x}$. A iteração continua sendo:

$$\tilde{x}^{(k+1)} = \tilde{x}^{(k)} - \tilde{J}^{-1}(\tilde{x}^{(k)}) F(\tilde{x}^{(k)})$$

A aproximação polinomial de Taylor gera bons resultados apenas em situações nos quais são necessários aproximações apenas nos pontos próximos a x_0 (ponto em relação ao qual é calculado o polinômio). Nos casos em que temos vários pontos e queremos achar um polinômio que passe por eles, precisamos de métodos alternativos.

O problema de determinação de um polinômio de 1ª Grau que passe pelos pontos distintos (x_0, y_0) e (x_1, y_1) é o mesmo que aproximar uma função $f(x)$ para a qual $f(x_0) = y_0$ e $f(x_1) = y_1$ por meio de um polinômio interpolador de 1ª Grau, ou seja, um polinômio que coincida com os valores de $f(x)$ nos pontos dados.

Em primeiro lugar definimos as funções:

$$L_0(x) = \frac{x - x_1}{x_0 - x_1} \quad \text{e} \quad L_1(x) = \frac{x - x_0}{x_1 - x_0} \quad (1)$$

e então definimos:

$$P(x) = L_0(x) f(x_0) + L_1(x) f(x_1) \quad (2)$$

Note que $L_0(x_0) = 1$, $L_0(x_1) = 0$, $L_1(x_0) = 0$ e $L_1(x_1) = 1$

$$\text{Logo } P(x_0) = y_0 \quad \text{e} \quad P(x_1) = y_1 \quad (3).$$

Então $P(x)$ acima é a única função linear que passa por (x_0, y_0) e (x_1, y_1) .

Para generalizar o conceito acima descrito, considere a construção de um polinômio de Grau no máximo n que passe pelos $n+1$ pontos

$$(x_0, f(x_0)), (x_1, f(x_1)), \dots, (x_n, f(x_n))$$

Neste caso é necessário construir para cada $k=0, 1, \dots, n$ uma função $L_{n,k}(x)$ com a propriedade de que $L_{n,k}(x_i) = 0$ quando $i \neq k$ e $L_{n,k}(x_k) = 1$. Para satisfazer $L_{n,k}(x_i) = 0$ para cada $i \neq k$ é necessário que o numerador de $L_{n,k}(x_k)$ contenha o termo:

$$(x - x_0)(x - x_1) \dots (x - x_{k-1})(x - x_{k+1}) \dots (x - x_n) \quad (4)$$

Para satisfazer $L_{n,k}(x_k) = 1$, o denominador de $L_{n,k}(x)$ deve ser igual ao termo acima calculado em $x = x_k$, ou seja

$$L_{n,k} = \frac{(x - x_0) \dots (x - x_{k-1})(x - x_{k+1}) \dots (x - x_n)}{(x_k - x_0) \dots (x_k - x_{k-1})(x_k - x_{k+1}) \dots (x_k - x_n)} \quad (5)$$

O polinômio interpolador é facilmente descrito como segue que a forma de $L_{n,k}$ seja conhecida. Esse polinômio, chamado n -ésimo polinômio interpolador de Lagrange, é definido

$$\text{como: } P(x) = f(x_0)L_{n,0}(x) + \dots + f(x_n)L_{n,n}(x) = \sum_{k=0}^n f(x_k)L_{n,k}(x) \quad (6)$$

onde $L_{n,k}(x)$ é dado por (5), que pode ser compactamente descrito como:

$$\prod_{\substack{i=0 \\ i \neq k}}^n \frac{(x - x_i)}{(x_k - x_i)} \quad (7)$$

Erro envolvido na interpolação

Prova-se que o erro envolvido na aproximação de uma função por um polinômio interpolador, para um x qualquer, ^{em $[a, b]$} tem a forma:

$$f(x) = P(x) + \frac{f^{(n+1)}(\xi(x))}{(n+1)!} (x - x_0)(x - x_1) \dots (x - x_n) \quad (8)$$

onde $P(x)$ é dado por (6). Aqui, $x_0, x_1, \dots$ são números distintos

no intervalo $[a, b]$, $f \in C^{n+1}[a, b]$ e $f(x)$ é um mínimo em $[a, b]$ (23)
 $\uparrow$
 a ordem + 1 derivada de f é contínua (pelo menos em $[a, b]$)
 geralmente desconhecido).

Infelizmente o termo de erro de Lagrange (eq. (8)) não pode ser avaliado muito frequentemente porque geralmente não conhecemos $f(x)$ (e consequentemente sua ordem + 1 derivada).

A prática usual é calcular os resultados fornecidos por diversos polinômios (de diferentes graus) até que se obtenha a coincidência adequada a seguir obtida. Para isso, vamos desenvolver um método para qual recorreremos às equações de Lagrange. Este método alternativo tem como base o seguinte teorema:

Seja f definida em $x_0, x_1, \dots, x_k$, e sejam x_i e x_j dois números distintos nesse conjunto. Então:

$$P(x) = \frac{(x - x_j) P_{0,2,\dots,i-1,i+1,\dots,k}(x) - (x - x_i) P_{0,2,\dots,i-1,i+1,\dots,k}(x)}{(x_i - x_j)} \quad (9)$$

descreve o único polinômio de Lagrange que interpola f nos $k+1$ pontos $x_0, x_1, \dots, x_k$.

O teorema acima implica que os polinômios interpoladores podem ser gerados de forma recursiva. Por exemplo, eles podem ser gerados da maneira mostrada na tabela a seguir, onde cada linha é completada antes que as linhas que a sucedem sejam iniciadas.

$$\begin{aligned}
 x_0 \quad P_0 &= G_{0,0} \\
 x_1 \quad P_1 &= G_{1,0} \quad P_{0,1} = G_{1,1} \\
 x_2 \quad P_2 &= G_{2,0} \quad P_{1,2} = G_{2,1} \quad P_{0,1,2} = G_{2,2} \\
 x_3 \quad P_3 &= G_{3,0} \quad P_{2,3} = G_{3,1} \quad P_{1,2,3} = G_{3,2} \quad P_{0,1,2,3} = G_{3,3} \\
 x_4 \quad P_4 &= G_{4,0} \quad P_{3,4} = G_{4,1} \quad P_{2,3,4} = G_{4,2} \quad P_{1,2,3,4} = G_{4,3} \quad P_{0,1,2,3,4} = G_{4,4} \dots
 \end{aligned}$$

Este procedimento é chamado método de Neville.

Exemplo:

Ache a aproximação de $f(1,5)$ utilizando o método de Neville

dado o parâmetro:

x	$f(x)$
$x_0 \quad 1,0$	$0,7651977$
$x_1 \quad 1,3$	$0,6200860$
$x_2 \quad 1,6$	$0,4554022$
$x_3 \quad 1,9$	$0,2818186$
$x_4 \quad 2,2$	$0,1103623$

Polinômios de grau 0: $G_{0,0} = f(x_0)$; $G_{1,0} = f(x_1)$; $G_{2,0} = f(x_2)$; ...

Polinômios de grau 1:

$$G_{1,1}(x) = \frac{(x-x_0)G_{1,0} - (x-x_1)G_{0,0}}{x_1 - x_0} =$$

$$= \frac{(1,5-1,0)G_{1,0} - (1,5-1,3)G_{0,0}}{1,3-1,0} = 0,523349$$

Da mesma forma $G_{2,1} = \frac{(x-x_1)G_{2,0} - (x-x_2)G_{1,0}}{x_2 - x_1} = 0,5102268$

Da mesma forma temos $G_{3,1} = 0,5132634$ e $G_{4,1} = 0,5104270$

Polinômios de grau 2:

$$G_{2,2} = \frac{(x-x_0)G_{2,1} - (x-x_2)G_{1,1}}{x_2 - x_0} = 0,5124715$$


$$G_{3,2} = \frac{(x-x_1)G_{3,1} - (x-x_3)G_{2,1}}{x_3 - x_1} = 0,5112857$$

$$G_{4,2} = \frac{(x-x_2)G_{4,1} - (x-x_4)G_{3,1}}{x_4 - x_2} = 0,5137361$$

} confira!

Interpolação por Spline Cúbico

2



O objetivo é interpolar um polinômio de 3º grau entre cada par de pontos de maneira que a curva resultante seja contínua, ^{e passe por todos os pontos dados} bem como tenha a 1ª e a 2ª derivadas também contínuas.

Forma geral do polinômio de 3º grau:
 $ax^3 + bx^2 + cx + d$

Note que na figura temos 4 polinômios de 3º grau para determinar (S_0, S_1, S_2, S_3). Cada polinômio de 3º grau tem 4 coeficientes. Logo, tenho 16 incógnitas no meu problema ($a_0, b_0, c_0, d_0, a_1, b_1, c_1, d_1, a_2, b_2, c_2, d_2, a_3, b_3, c_3, d_3$). Nesse sentido, preciso de 16 equações para resolver o problema.

— Equações de 1º tipo

Estas equações garantem que a curva resultante passa por todos os pontos dados:

$$\Rightarrow \begin{cases} a_0 x_0^3 + b_0 x_0^2 + c_0 x_0 + d_0 = y_0 \\ a_0 x_1^3 + b_0 x_1^2 + c_0 x_1 + d_0 = y_1 \\ a_1 x_1^3 + b_1 x_1^2 + c_1 x_1 + d_1 = y_1 \\ a_1 x_2^3 + b_1 x_2^2 + c_1 x_2 + d_1 = y_2 \\ a_2 x_2^3 + b_2 x_2^2 + c_2 x_2 + d_2 = y_2 \\ a_2 x_3^3 + b_2 x_3^2 + c_2 x_3 + d_2 = y_3 \\ a_3 x_3^3 + b_3 x_3^2 + c_3 x_3 + d_3 = y_3 \\ a_3 x_4^3 + b_3 x_4^2 + c_3 x_4 + d_3 = y_4 \end{cases} \quad \text{8 equações} \quad (2)$$

- Equações de 2º tipo

Estas equações garantem a continuidade da 1ª derivada da curva resultante.

Forma geral da 1ª derivada de um polinômio de 3º grau:

$$3ax^2 + 2bx + c$$

$$\Rightarrow \begin{cases} 3a_0 x_1^2 + 2b_0 x_1 + c_0 = 3a_1 x_1^2 + 2b_1 x_1 + c_1 & (S'_0 = S'_1 \text{ em } x_1) \\ 3a_1 x_2^2 + 2b_1 x_2 + c_1 = 3a_2 x_2^2 + 2b_2 x_2 + c_2 & (S'_1 = S'_2 \text{ em } x_2) \\ 3a_2 x_3^2 + 2b_2 x_3 + c_2 = 3a_3 x_3^2 + 2b_3 x_3 + c_3 & (S'_2 = S'_3 \text{ em } x_3) \end{cases} \quad \text{3 equações}$$

- Equações do 3º tipo

Estas equações garantem a continuidade da 2ª derivada da curva resultante.

Forma geral da 2ª derivada de um polinômio de 3º grau:

$$6ax + 2b$$

③

$$\Rightarrow \begin{cases} 6a_0x_1 + 2b_0 = 6a_1x_1 + 2b_1 & (S_0'' = S_1'' \text{ em } x_1) \\ 6a_1x_2 + 2b_1 = 6a_2x_2 + 2b_2 & (S_1'' = S_2'' \text{ em } x_2) \\ 6a_2x_3 + 2b_2 = 6a_3x_3 + 2b_3 & (S_2'' = S_3'' \text{ em } x_3) \end{cases} \quad \begin{matrix} 3 \\ \text{equações} \end{matrix}$$

Até agora temos $8+3+3=14$ equações. Precisamos de mais 2 equações. Estas equações vêm da atribuição de valores para a 1ª e/ou 2ª derivada nos extremos da curva, e são conhecidos como condições de contorno. Geralmente, são dados do problema. Por exemplo, podemos querer que a 1ª derivada em x_0 seja 0 e a 2ª derivada em x_4 seja -2.5 .

$$\Rightarrow \begin{cases} 3a_0x_0^2 + 2b_0x_0 + c_0 = 0 & (S_0' = 0 \text{ em } x_0) \\ 6a_3x_4 + 2b_3 = -2.5 & (S_3'' = -2.5 \text{ em } x_4) \end{cases} \quad \begin{matrix} 2 \\ \text{equações} \end{matrix}$$

Agora temos $8+3+3+2=16$ equações. Logo, podemos resolver o problema. A representação matricial do sistema linear resultante é:

Representação matricial do sistema:


rozpisání matrice do systému:																		
x_0^3	x_0^2	x_0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	a_0	y_0
x_1^3	x_1^2	x_1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	b_0	y_1
0	0	0	0	x_1^3	x_1^2	x_1	1	0	0	0	0	0	0	0	0	0	c_0	y_1
0	0	0	0	x_2^3	x_2^2	x_2	1	0	0	0	0	0	0	0	0	0	d_0	y_2
0	0	0	0	0	0	0	0	x_2^3	x_2^2	x_2	1	0	0	0	0	0	a_1	y_2
0	0	0	0	0	0	0	0	x_3^3	x_3^2	x_3	1	0	0	0	0	0	b_1	y_3
0	0	0	0	0	0	0	0	0	0	0	0	x_3^3	x_3^2	x_3	1	c_1	y_3	
$3x_1^2$	$2x_1$	1	0	$-3x_1^2$	$-2x_1$	-1	0	0	0	0	0	x_4^3	x_4^2	x_4	1	d_1	y_4	
0	0	0	0	$3x_1^2$	$2x_1$	1	0	$-3x_1^2$	$-2x_1$	-1	0	0	0	0	0	a_2	0	
0	0	0	0	0	0	0	0	$3x_2^2$	$2x_2$	1	0	$-3x_2^2$	$-2x_2$	-1	0	b_2	0	
$6x_1$	2	0	0	$-6x_1$	-2	0	0	0	0	0	0	$3x_3^2$	$2x_3$	1	0	c_2	0	
0	0	0	0	$6x_1$	2	0	0	$-6x_1$	-2	0	0	0	0	0	0	d_2	0	
0	0	0	0	0	0	0	0	$6x_2$	2	0	0	$-6x_2$	-2	0	0	a_3	0	
$3x_0^2$	$2x_0$	1	0	0	0	0	0	0	0	0	0	0	0	0	0	b_3	0	
0	0	0	0	0	0	0	0	0	0	0	0	$6x_3$	2	0	0	c_3	0	
																d_3	-2,5	

APROXIMAÇÕES POR MÍNIMOS QUADRADOS DISCRETOS

31


Considere o problema de obter estimativas para os valores de uma função em pontos não tabulados, quando são fornecidos os dados experimentais apresentados na tabela e gráfico abaixo:

x_i	y_i
2	1.3
2	3.5
3	4.2
4	5.0
5	7.0
6	8.8
7	10.1
8	12.5
9	13.0
10	15.6



O gráfico acima "sugere" que a relação entre y e x é linear. A razão provável de nenhuma reta ajustar precisamente os dados é a presença de erro (ruído) nos dados.

Abaixo, temos o esboço do polinômio de 9º grau que passa pelos 10 pontos dados.



Note que o polinômio acima apresenta oscilações (especialmente

entre os 3° e 10° pontos) que não estavam presentes originalmente. ⁽³²⁾
 Este polinômio é claramente um preditor ruim de informações entre os diversos pontos dados. Uma abordagem mais acertada seria encontrar a "melhor" (em algum sentido) reta de aproximação, mesmo que ela não coincida precisamente com os dados em nenhum ponto.

Podemos imaginar alguns procedimentos diferentes para realizar esta tarefa, cada qual envolvendo a minimização de uma função diferente.

O método dos mínimos quadrados estudado a seguir é o método mais utilizado e mais adequado para determinar a relação linear desejada. Neste método, devemos nos encontrar com as constantes a_0 e a_1 que minimizam os erros de mínimos quadrados:

$$E_2(a_0, a_1) = \sum_{i=1}^m [y_i - (a_1 x_i + a_0)]^2 \quad (1)$$

Para que ocorra um mínimo é necessário que:

$$\frac{\partial}{\partial a_0} (E_2(a_0, a_1)) = 0 \quad (2) \quad \text{e} \quad \frac{\partial}{\partial a_1} (E_2(a_0, a_1)) = 0 \quad (3)$$

Na equação (2) temos que:

$$2 \sum_{i=1}^m (y_i - a_1 x_i - a_0)(-1) = 0 \Rightarrow a_0 \cdot m + a_1 \sum_{i=1}^m x_i = \sum_{i=1}^m y_i \quad (4)$$

E da equação (3) temos que:

$$2 \sum_{i=1}^m (y_i - a_1 x_i - a_0)(-x_i) = 0 \Rightarrow a_0 \sum_{i=1}^m x_i + a_1 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m x_i y_i \quad (5)$$

Podemos compactar a notação escrevendo (4) e (5) como:

$$a_0 \cdot m + a_1 S_1 = S_2 \quad (6) \quad \text{e} \quad a_0 S_2 + a_1 S_3 = S_4 \quad (7)$$

onde $S_1 = \sum_{i=1}^m x_i$; $S_2 = \sum_{i=1}^m y_i$; $S_3 = \sum_{i=1}^m x_i^2$ e $S_4 = \sum_{i=1}^m x_i y_i$

De (6) temos que $a_0 = \frac{S_2 - a_1 S_1}{m}$ (8). (8) em (7):

$$\frac{S_2 - a_1 S_1}{m} S_2 + a_1 S_3 = S_4 \Rightarrow S_2 - a_1 S_1 + m a_1 S_3 = m S_4 \Rightarrow m a_1 S_3 - a_1 S_1 = m S_4 - S_2$$

$$\Rightarrow a_1 (m S_3 - S_1) = m S_4 - S_2 \Rightarrow a_1 = \frac{m S_4 - S_2 S_1}{m S_3 - S_1^2} \quad (9)$$

"Plugando-se" (9) em (8) acha-se a_0 .

Exemplo: (Exemplo 1 da pág 462 do livro de Burden).

Ajuste de curvas de 2º Grau

Analogamente ao que foi desenvolvido previamente, podemos escrever os erros de mínimos quadrados como:

$$E_2(a_0, a_1, a_2) = \sum_{i=1}^m [y_i - (a_2 x_i^2 + a_1 x_i + a_0)]^2 \quad (10)$$

Para que ocorra um mínimo é necessário que:

$$\frac{\partial E_2(a_0, a_1, a_2)}{\partial a_0} = 0 \quad (11) \quad ; \quad \frac{\partial E_2(a_0, a_1, a_2)}{\partial a_1} = 0 \quad (12) \quad \text{e} \quad \frac{\partial E_2(a_0, a_1, a_2)}{\partial a_2} = 0 \quad (13)$$

Isso nos leva a um sistema linear de 3 equações. (P/Corr: Desenvolva este sistema)

Ajuste de curvas de 2º Grau

$$E_2(a_0, a_1, a_2) = \sum_{i=1}^m [y_i - (a_2 x_i^2 + a_1 x_i + a_0)]^2$$

Para que ocorra um mínimo é necessário que $\frac{\partial E_2}{\partial a_0} = 0$; $\frac{\partial E_2}{\partial a_1} = 0$ e $\frac{\partial E_2}{\partial a_2} = 0$

$\frac{\partial E_2}{\partial a_0}$: Chamando $f = y_i - (a_2 x_i^2 + a_1 x_i + a_0)$ e $g = f^2$, temos, pela

regra da cadeia que: $\frac{\partial g}{\partial a_0} = \frac{\partial g}{\partial f} \frac{\partial f}{\partial a_0} = 2f(-1)$

Analogamente $\frac{\partial E_2}{\partial a_1} = \frac{\partial g}{\partial a_1} = \frac{\partial g}{\partial f} \frac{\partial f}{\partial a_1} = 2f(-x_i)$ e $\frac{\partial E_2}{\partial a_2} = \frac{\partial g}{\partial a_2} = \frac{\partial g}{\partial f} \frac{\partial f}{\partial a_2} = 2f(-x_i^2)$

$$\Rightarrow \begin{cases} \frac{\partial E_2}{\partial a_0} = 0 : 2f(-1) = 0 \Rightarrow a_2 \sum_{i=1}^m x_i^2 + a_1 \sum_{i=1}^m x_i + a_0 m = \sum_{i=1}^m y_i & 1^a \text{ eq.} \\ \frac{\partial E_2}{\partial a_1} = 0 : 2f(-x_i) = 0 \Rightarrow a_2 \sum_{i=1}^m x_i^3 + a_1 \sum_{i=1}^m x_i^2 + a_0 \sum_{i=1}^m x_i = \sum_{i=1}^m (y_i x_i) & 2^a \text{ eq.} \\ \frac{\partial E_2}{\partial a_2} = 0 : 2f(-x_i^2) = 0 \Rightarrow a_2 \sum_{i=1}^m x_i^4 + a_1 \sum_{i=1}^m x_i^3 + a_0 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m (y_i x_i^2) & 3^a \text{ eq.} \end{cases}$$

Ajuste de curva de 3º Grau

$$E_3(a_0, a_1, a_2, a_3) = \sum_{i=1}^m [y_i - (a_3 x_i^3 + a_2 x_i^2 + a_1 x_i + a_0)]^2$$

Chamando $f = y_i - (a_3 x_i^3 + a_2 x_i^2 + a_1 x_i + a_0)$ e $g = f^2$, e utilizando a regra da cadeia, podemos escrever que:

$$\begin{cases} \frac{\partial E_3}{\partial a_0} = 0 : a_3 \sum x_i^3 + a_2 \sum x_i^2 + a_1 \sum x_i + m a_0 = \sum y_i & 1^a \text{ eq.} \\ \frac{\partial E_3}{\partial a_1} = 0 : a_3 \sum x_i^4 + a_2 \sum x_i^3 + a_1 \sum x_i^2 + a_0 \sum x_i = \sum (y_i x_i) & 2^a \text{ eq.} \\ \frac{\partial E_3}{\partial a_2} = 0 : a_3 \sum x_i^5 + a_2 \sum x_i^4 + a_1 \sum x_i^3 + a_0 \sum x_i^2 = \sum (y_i x_i^2) & 3^a \text{ eq.} \\ \frac{\partial E_3}{\partial a_3} = 0 : a_3 \sum x_i^6 + a_2 \sum x_i^5 + a_1 \sum x_i^4 + a_0 \sum x_i^3 = \sum (y_i x_i^3) & 4^a \text{ eq.} \end{cases}$$

Ajuste de curvas exponenciais

(34)

Ocasionalmente, é apropriado supor que os dados estejam relacionados exponencialmente. Isso requer que a função de aproximação seja do tipo

$$y = b e^{ax} \quad (14) \quad \text{ou} \quad y = b x^a \quad (15)$$

onde a e b são constantes.

A dificuldade de se aplicar o procedimento de mínimos quadrados a uma situação desse tipo vem do fato que o sistema 2×2 resultante, geralmente, não possui solução exata.

O método que é normalmente utilizado quando se suspeita que os dados estejam relacionados exponencialmente é considerar o logaritmo da equação de aproximação:

$$\text{(de (14)) } \ln y = \ln b + ax \quad (16) \quad \text{e} \quad \text{(de (15)) } \ln y = \ln b + a \ln x \quad (17)$$

Em ambos os casos aparece um problema linear cujas soluções para $\ln b$ e a podem ser obtidas de modo análogo ao método descrito anteriormente para ajuste de retas.